RELATÓRIO GERENCIAL · DESAFIO DE OBSERVABILIDADE

Plano de Observabilidade: Conta-corrente e Clientes

Instituto de Ciência e Tecnologia Itaú · Marco Aurélio Costa da Silva · Outubro de 2026

1. Resumo executivo

Objetivo. Definir como observar seis serviços (aproximadamente 104 mil requisições por dia) para detectar falhas antes que o cliente as perceba.

Solução. Três pilares (métricas, logs e traces), quatro golden signals, SLOs propostos com orçamento de erro, métricas de negócio e 14 alarmes com critérios numéricos explícitos.

Validação. Simulador com ferramentas gratuitas e três falhas injetadas (um experimento por cenário). Nos três cenários, foram observados os sinais de detecção previstos, como evidência inicial.

Achado principal. Nos experimentos, cada falha foi revelada por um sinal diferente: erros pelo burn rate, lentidão pelo p99 e queda total pelo *up* e pelo tráfego. Nenhum sinal isolado cobriu os três casos.

Recomendação. Adotar o plano, com alertas por burn rate e monitoramento da consistência entre serviços, e evoluir para OpenTelemetry, Loki e CloudWatch.

2. Contexto e volumetria

Serviço	Volume/dia	Taxa média	Implicação para os alertas
Movimentação de saldo	100.000	≈ 1,2 req/s	SLO rigoroso e alertas por burn rate
Cadastro de contas	1.000	≈ 42 req/h	Taxa de erro só com volume mínimo
Cancelamento de contas	200	≈ 8 req/h	Janela de 1 h e contagem absoluta
Bloqueio por fraude	700	≈ 29 req/h	Baixo volume e alta criticidade: janela de 15 min
Inclusão de clientes	2.000	≈ 83 req/h	Taxa de erro só com volume mínimo
Inativação de clientes	100	≈ 4 req/h	Contagem absoluta

Por que o volume importa. Com poucas dezenas de eventos por hora, uma única falha muda a taxa de erro de forma expressiva (1 erro em 3 requisições equivale a 33%). Por isso, nesses serviços o plano usa janelas longas, volume mínimo e contagem absoluta, em vez de taxa em 5 minutos.

3. Plano de observabilidade

3.1 Os três pilares

Os três pilares seguem a formulação de Sridharan (2018).

Pilar	Pergunta que responde	Implementação no experimento	Opções em produção
Métricas	O que está errado?	Prometheus e Grafana: histogramas, contadores e gauges	CloudWatch ou Datadog
Logs	O que aconteceu?	JSON com trace_id; sem CPF nem conta em claro (LGPD)	Loki ou CloudWatch Logs
Traces	Onde ocorreu?	trace_id propagado entre os serviços (versão simplificada)	OpenTelemetry e Tempo ou X-Ray

3.2 Golden signals

Os quatro sinais seguem Beyer et al. (2016). A latência usa histogramas do Prometheus (Prometheus Authors), que permitem estimar percentis.

Sinal	Indicador	Observação
Latência	p50, p95 e p99 por operação (histograma)	A média esconde a cauda; alarme com p99 acima de 0,8 s
Tráfego	Requisições por segundo por operação	Base para detectar queda silenciosa
Erros	Respostas 5xx sobre o total	Saldo insuficiente (422) é regra de negócio e não consome o SLO
Saturação	Pool de conexões, threads, CPU e memória	Aviso antecipado com pool acima de 80%

3.3 SLOs propostos e orçamento de erro

Natureza das metas. O enunciado não fornece SLAs nem SLOs. As metas abaixo são propostas iniciais desta solução e devem ser validadas com o negócio e calibradas com dados reais de produção.

- **Movimentação:** 99,9% de disponibilidade e 99% das requisições abaixo de 300 ms.
- **Fraude:** 99,5% dos bloqueios efetivados em menos de 2 s. **Demais serviços:** 99,5% de disponibilidade.

Requisições elegíveis. A disponibilidade considera todas as requisições HTTP da operação. Respostas 5xx são falhas; respostas 422 (saldo insuficiente) e demais 4xx são tratadas como respostas válidas, por representarem regras de negócio, e não consomem o orçamento.

Orçamento de erro e burn rate. O SLO de 99,9% admite 0,1% de falhas. Em um mês de 30 dias e com volume constante de 100 mil requisições por dia, o orçamento da movimentação corresponde a aproximadamente 3.000 falhas (cerca de 100 por dia). O alarme de *burn rate* segue a abordagem multijanela do SRE Workbook (Beyer et al., 2018): o limite é 14,4 vezes o consumo sustentável do orçamento, ou seja, taxa de erro acima de 1,44%. **O alarme exige as duas condições ao mesmo tempo**: a janela de 1 h confirma que o consumo é relevante e a de 5 min garante que o problema ainda está ativo. Exceder o limite em apenas uma das janelas não dispara o alarme, o que reduz falsos positivos e encerra o alerta logo após a correção. Nesse ritmo, 2% do orçamento mensal se esgota em 1 hora.

3.4 Métricas de negócio

- Movimentações por tipo e resultado, e valor movimentado em R$.
- Contas abertas e canceladas; clientes incluídos e inativados; bloqueios de fraude por motivo e tempo até a efetivação.
- **Inconsistência cliente x conta:** clientes inativados cujas contas seguem ativas (deve ser sempre zero). É a métrica transversal que revela falhas na comunicação entre os serviços.

3.5 Alarmes: critérios de disparo (14 regras)

Nível	Alarme	Condição de disparo	Janela e persistência
Crítico	Serviço fora do ar	Alvo sem resposta ao scrape (up == 0)	Persistência de 1 min
Crítico	Burn rate da movimentação	Taxa de 5xx acima de 1,44% (14,4x o orçamento de 0,1%) nas duas janelas ao mesmo tempo	5 min e 1 h; persistência de 2 min
Crítico	Erros 5xx na movimentação	Razão de 5xx acima de 2%	5 min; persistência de 2 min
Crítico	p99 da movimentação	p99 acima de 0,8 s	5 min; persistência de 2 min
Crítico	Sem tráfego na movimentação	Serviço ativo sem requisições (taxa igual a zero) ou métrica ausente (alvo indisponível, redundante com up == 0)	5 min; persistência de 3 min
Crítico	Fraude lenta	Proporção de bloqueios acima de 2 s superior a 5% (10x o orçamento de 0,5%), com pelo menos 20 bloqueios	1 h; imediato

Nível	Alarme	Condição de disparo	Janela e persistência
Crítico	Fraude com falhas	3 ou mais respostas 5xx no bloqueio por fraude	15 min; imediato
Crítico	Inconsistência cliente x conta	Qualquer inativação de cliente sem cancelamento da conta (contador maior que 0)	15 min; imediato
Aviso	Pool de conexões saturado	Conexões em uso acima de 80% da capacidade	Persistência de 2 min
Aviso	Falhas de cancelamento	3 ou mais respostas 5xx no cancelamento	1 h; imediato
Aviso	Erros no cadastro	5xx acima de 5%, com pelo menos 20 requisições	30 min; imediato
Aviso	Erros na inclusão de clientes	5xx acima de 5%, com pelo menos 20 requisições	30 min; imediato
Anomalia	Queda de movimentações	Taxa abaixo de 50% da taxa de 15 min antes, com base anterior acima de 1 req/s	5 min; persistência de 5 min
Anomalia	Pico de bloqueios de fraude	Bloqueios acima de 3x o valor de 1 h antes, com pelo menos 10 bloqueios	15 min; imediato

Limites de acionamento e metas. Os limites de página (erros acima de 2% e p99 acima de 0,8 s) são mais folgados que as metas (0,1% e 300 ms) por desenho: o burn rate acompanha o consumo do orçamento, e o limite de página evita acionar o plantão por desvios pequenos.

Fraude lenta. O alarme mede a proporção de bloqueios acima de 2 s, alinhada ao SLO de 99,5%. O cálculo usa o histograma: (total de bloqueios menos os efetivados em até 2 s) dividido pelo total. Com limite de 5% (10 vezes o orçamento de 0,5%) e mínimo de 20 bloqueios, bastam 2 bloqueios lentos em 20 observações; no volume esperado (≈ 29 por hora), cerca de 2 em 1 h. Em horas com menos de 20 bloqueios o alarme não é avaliado, o que é uma limitação do critério. A regra foi redefinida após os experimentos, não foi exercitada em nenhum cenário e sua forma de cálculo ainda precisa ser validada.

4. Validação experimental

Método. Simulador em Python (FastAPI) com os seis serviços, Prometheus e Grafana, em notebook com 8 GB de RAM (≈ 600 MB utilizados). A carga foi de 10 req/s, mantendo a proporção da volumetria (compressão temporal ≈ 8x, já que a média real é ≈ 1,2 req/s). Em cada cenário: linha de base de 5 min, injeção da falha por mais de 9 min e recuperação.

Hipóteses. H1: falhas 5xx são detectadas por burn rate e a cascata gera inconsistência visível na métrica de negócio. H2: lentidão sem erro só é detectada pelo p99. H3: indisponibilidade total é detectada por *up* e tráfego, e não por taxa de erro.

Indicador medido	Linha de base	Cenário 1: erros 5xx	Cenário 2: lentidão	Cenário 3: serviço fora
Falha injetada	Nenhuma	50% de erros 5xx	+0,8 s de latência	Indisponibilidade do serviço de conta-corrente por aproximadamente 9 minutos
Disponibilidade (15 min)	100%	64,1%	99,9%	Sem dados (sem tráfego)
p99 da movimentação	≈ 240 ms	≈ 250 ms	1,98 s	Sem dados
Alertas em Firing	0	6	1	3
O que detectou	-	Burn rate e erro 5xx	Latência p99	up == 0 e falta de tráfego
Efeito no negócio	-	Queda de 55% (300 para 130/min)	Sem alteração	Movimentações = 0
Inconsistência cliente x conta	0	5	0	5 (pico de 7 ao religar)
Recuperação	-	Disponibilidade 100%	p99 261 ms e 0 alertas	Disp. 99,9%, p99 249 ms e 0 alertas

Valores lidos nos painéis do Grafana e do Prometheus, em um único experimento por cenário.

Como ler os 64,1% do cenário 1. A disponibilidade é 1 menos a razão de respostas 5xx sobre o total de requisições da movimentação, em janela móvel de 15 min (o 422 de saldo insuficiente não conta). A falha de 50% foi ativada alguns minutos depois do início da carga e a leitura ocorreu cerca de 10 min após a injeção: a janela ainda incluía tráfego sem falha e a taxa de erro subiu de forma gradual. Com 50% de erros em cerca de dois terços da janela, a estimativa fica entre 63% e 67%, a mesma ordem de grandeza dos 64,1% medidos. Trata-se de uma aproximação, e não de um valor teórico exato, pois o instante da injeção não foi registrado em log.

Pool de conexões no cenário 2. Observado: o pool atingiu picos de 100%, mas oscilou (cerca de 60% a 100% nas leituras de 15 s) e o aviso de pool não disparou, pois a regra exige mais de 80% de forma contínua por 2 min; por isso só um alerta (p99) ficou em Firing. **Recomendado, não testado:** avaliar a média ou o máximo do pool em janela de 2 min, para reduzir a sensibilidade a oscilações.

Resultado. Os resultados observados foram compatíveis com as três hipóteses nos experimentos realizados. Como foi executado um único experimento por cenário, os resultados são evidências iniciais, ainda sem repetição estatística.

No cenário 2 a disponibilidade permaneceu em 99,9% enquanto o p99 passou de 0,24 s para 1,98 s: monitorar só disponibilidade deixaria a degradação invisível. No cenário 3 a série de erros desapareceu em vez de subir: serviço fora do ar gera silêncio, não erro.

4.1 Medidas recomendadas para produção

Esta seção separa o medido (tabela acima) do recomendado. Nenhuma das medidas abaixo foi implementada ou testada no experimento.

Cenário	Protetiva principal (antes)	Corretiva principal (depois)
1. Erros 5xx	• Deploy gradual com rollback guiado pelo burn rate • Fila persistente para a cascata cliente → conta	• Reverter a versão com falha • Reprocessar e reconciliar inativações sem cancelamento
2. Lentidão	• Timeouts, limite de concorrência e teste de carga com meta de p99	• Escalar instâncias e ampliar o pool • Localizar a operação lenta por traces e logs
3. Serviço fora	• Ao menos 2 réplicas, com health check e reinício automático	• Reiniciar ou fazer failover • Reprocessar eventos pendentes e reconciliar clientes e contas

5. Conclusões, limitações e próximos passos

- **Alertar por sintoma e por burn rate,** não por causa: reduz ruído e prioriza o que afeta o cliente.
- **Incluir métricas de negócio transversais:** a inconsistência entre serviços só foi revelada por elas.
- **Tratar o baixo volume de forma específica:** janelas longas, volume mínimo e contagem absoluta.
- **Vigiar o próprio monitoramento:** alertas de *up* e de tráfego cobrem a ausência de dados.

Limitações. Um experimento por cenário (sem réplicas); simulador sem banco de dados real e com estado em memória; traces simplificados; SLOs e limiares ainda não calibrados com dados de produção; alarme de fraude lenta redefinido após os experimentos e não exercitado.

Próximos passos. Adotar OpenTelemetry com Tempo, Loki, Alertmanager (Telegram ou e-mail) e CloudWatch na AWS, e calibrar SLOs e limiares com dados reais, em conjunto com o negócio.